ESCUELA POLITÉCNICA NACIONAL

FACULTAD DE SISTEMAS

ASISTENTE SOCIOTÉCNICO BASADO EN MODELOS DE LENGUAJE PARA LA DELIBERACIÓN ACADÉMICA EN LA RED SOCIAL DE LA PLATAFORMA CENTINELA V3

PROYECTO PREVIO A LA OBTENCIÓN DEL TÍTULO DE INGENIERÍA DE SOFTWARE

ALEXANDER XAVIER MOTOCHE VIRACOCHA
alexander.motocheo@epn.edu.ec

Director: LORENA KATHERINE RECALDE CERDA
lorena.recalde@epn.edu.ec

QUITO, 2026

DECLARACIÓN

Yo ALEXANDER XAVIER MOTOCHE VIRACOCHA, declaro bajo juramento que el trabajo aquí escrito es de mi autoría; que no ha sido previamente presentado para ningún grado o calificación profesional; y que he consultado las referencias bibliográficas que se incluyen en este documento.

A través de la presente declaración cedo mis derechos de propiedad intelectual, correspondientes a este trabajo, a la Escuela Politécnica Nacional, según lo establecido por la Ley de Propiedad Intelectual, por su reglamento y por la normatividad institucional vigente.

Alexander Xavier Motoche Viracocha

CERTIFICACIÓN

Certifico que el presente trabajo fue desarrollado por ALEXANDER XAVIER MOTOCHE VIRACOCHA, bajo mi supervisión.

Lorena Katherine Recalde Cerda
Director del Proyecto

AGRADECIMIENTOS

...

DEDICATORIA

Para .....

Índice general

Resumen VIII

Abstract IX

1. Introducción 1

2. Marco Teórico 2

2.1. Argumentación en Inteligencia Artificial 2

2.2. Sistemas de Preguntas y Respuestas 3

2.3. Generación Automática de Preguntas 4

2.4. Evaluación de la calidad en generación automática de preguntas . . . 5

2.5. Sistemas Sociotécnicos 6

2.5.1. Unidades de primer orden 6

2.5.2. Unidades de segundo orden 7

2.5.3. Complementariedad humano-máquina 7

2.6. Fine-Tuning en Modelos de Lenguaje 7

2.7. Deliberación Académica 9

2.8. Co-pensamiento y Cognición Híbrida (Humano-IA) 10

2.8.1. El rol de la IA como mediador en la deliberación 11

2.8.2. Riesgos epistémicos y descarga cognitiva 11

3. Metodología 12

3.1. CRISP-DM 12

3.1.1. Entendimiento del negocio 13

3.1.2. Comprensión de los datos 13
3.1.3. Preparación de los datos 13
3.1.4. Modelado 13
3.1.5. Evaluación 14
3.1.6. Despliegue 14
3.2. Kanban 14
3.2.1. Tableros Kanban 14
3.2.2. Tarjetas Kanban 15
3.2.3. Backlog 15
3.2.4. Métricas 15
3.3. Integración de metodologías y marcos de trabajo 15

Bibliografía **17**

Resumen

En el presente trabajo...

Abstract

In this paper...

Capítulo 1

Introducción

TEOREMA 1.1. *Bla bla bla*

En el Teorema 1.1

Capítulo 2

Marco Teórico

2.1. Argumentación en Inteligencia Artificial

Un argumento puede definirse como un conjunto de razones que sirven para apoyar una afirmación [3]. Esta afirmación no necesariamente busca demostrar una verdad absoluta, sino que en muchos casos intenta justificar una decisión o una acción que se debería realizar. Este tipo de razonamiento se presenta principalmente dentro de los procesos de razonamiento argumentativo.

La argumentación se refiere al proceso mediante el cual se proponen, discuten y evalúan afirmaciones [3]. A diferencia de la lógica formal o las pruebas matemáticas, donde existen estructuras precisas, axiomas y reglas que determinan cuándo una afirmación es verdadera o falsa, la argumentación cotidiana se desarrolla en contextos donde la información suele ser incompleta o incierta. Por esta razón, la validez de un argumento puede cambiar cuando se incorpora nueva información.

Uno de los enfoques más relevantes en este campo es el *defeasible reasoning*, el cual establece que un argumento puede considerarse válido en un momento determinado, pero puede dejar de serlo si aparece nueva evidencia o información adicional [3].

Cuando la argumentación ocurre entre múltiples participantes que presentan defensas, ataques o contraargumentos, este proceso se denomina diálogo. El estudio de estos diálogos es fundamental en sistemas de inteligencia artificial donde interactúan múltiples entidades o agentes [3].

Walton y Krabbe proponen una clasificación de los diálogos según su propósito principal:

- **Diálogo de persuasión**: busca resolver un desacuerdo mediante argumentos racionales.
- **Diálogo de búsqueda de información**: se centra en obtener o proporcionar conocimiento.
- **Diálogo de negociación**: intenta alcanzar acuerdos prácticos entre partes con intereses en conflicto.
- **Diálogo de investigación**: tiene como objetivo descubrir la verdad sobre una cuestión abierta.
- **Diálogo erístico**: surge del conflicto y busca expresar oposición más que resolver racionalmente el problema.

2.2. Sistemas de Preguntas y Respuestas

Los sistemas de preguntas y respuestas (Question Answering, QA) utilizan técnicas de procesamiento de lenguaje natural y recuperación de información para responder preguntas formuladas en lenguaje natural [8].

Estos sistemas pueden clasificarse según el dominio del conocimiento:

- **Dominio abierto**: responden preguntas sobre múltiples temas.
- **Dominio cerrado**: se especializan en un área específica.

También pueden clasificarse según la fuente de datos utilizada:

- Fuentes estructuradas como bases de datos, grafos de conocimiento o archivos JSON/XML.
- Fuentes no estructuradas como documentos o páginas web.

Desde el punto de vista de la interacción:

- **Single-turn QA**: cada pregunta se responde de manera independiente.
- **Multi-turn QA**: existe contexto conversacional entre preguntas [8].

El análisis de preguntas y respuestas puede abordarse mediante enfoques semánticos, ontológicos y estadísticos, los cuales permiten comprender el significado del texto y determinar la relevancia de las respuestas generadas [8].

Un ejemplo representativo es el sistema GenQA, que divide el proceso en tres componentes:

- *Interpreter*: transforma la pregunta en representaciones vectoriales.
- *Enquirer*: recupera información relevante.
- *Answerer*: genera la respuesta utilizando mecanismos de atención [8].

2.3. Generación Automática de Preguntas

La generación automática de preguntas (Question Generation, QG) busca producir preguntas a partir de texto, bases de conocimiento o documentos [10].

Para evaluar estos sistemas se utilizan métricas como BLEU, METEOR y ROUGE, así como evaluaciones humanas que consideran claridad, utilidad y corrección gramatical de las preguntas generadas [10].

Entre los componentes principales se encuentra el *input context text*, que corresponde a la fuente de información utilizada para generar preguntas.

Dependiendo del conocimiento previo de la respuesta, existen dos enfoques:

- **Answer-aware QG**: el sistema conoce la respuesta antes de generar la pregunta.
- **Answer-agnostic QG**: el sistema genera preguntas sin conocer una respuesta específica [10].

En el enfoque *answer-aware*, la respuesta puede ser:

- **Answer span**: aparece explícitamente en el texto.
- **Respuesta abstractiva**: debe inferirse a partir del contenido.

Finalmente, los sistemas QG pueden clasificarse según el tipo de pregunta generada:

- Preguntas independientes (*standalone*).
- Preguntas secuenciales dependientes del contexto.
- Preguntas de opción múltiple [10].

2.4. Evaluación de la calidad en generación automática de preguntas

La evaluación de la calidad en sistemas de generación de preguntas QG es medir en qué grado las preguntas que se generan son útiles, relevantes o coherentes.

Notemos que medir calidad en una pregunta es algo difícil de cuantificar, por lo que existen varios métodos que se pueden dividir en automáticos y manuales humanos [7].

En el caso de los automáticos, el más básico es la evaluación por similitud superficial. En este método se compara textualmente la pregunta generada con la pregunta de referencia hecha por una persona real. En este caso se mide la coincidencia de las palabras, donde el mejor resultado es el que tiene mayor similitud léxica.

La principal métrica usada de este tipo es la evaluación METEOR, dado que es la que tiene mayor flexibilidad léxica, ya que incluye coincidencia por sinónimos, raíces léxicas e incluye penalización por desorden. Usa la técnica F-score para calcular el valor.

F-score es un cálculo basado en dos componentes: la precisión y recall de un modelo. La precisión nos indica cuán correcto es la salida del modelo. El recall nos dice si el modelo es efectivo en encontrar los elementos de mi objetivo.

Con los nuevos modelos capaces de capturar el significado, por medio de arquitecturas basadas en transformers, se pueden hacer evaluaciones basadas en representaciones vectoriales.

Una de las métricas más usadas es BERTScore, que usa embeddings generados por modelos como BERT y se compara el vector de la pregunta generada con el vector de las preguntas de referencia. Esta métrica ofrece un mejor resultado, ya que no dependemos de comparaciones textuales, sino semánticas. Como resultado, es una evaluación más robusta, donde las palabras y orden son menos relevantes que el significado. Este enfoque mejora mucho la evaluación de sistemas de generación de preguntas.

Por último tenemos las evaluaciones manuales. Ya que las evaluaciones anteriores carentes de juicio humano pueden cometer errores y sesgos respecto a la calidad de las preguntas, este enfoque se centra en que una persona califique las preguntas que han sido generadas.

Los componentes que normalmente se califican de una pregunta generada son:

- Fluidez: naturalidad de la pregunta
- Relevancia: importancia y adecuada respecto al contexto
- Calidad global y utilidad: capacidad para ser respondida y generar conocimiento
- Corrección semántica: coherencia del significado

2.5. Sistemas Sociotécnicos

Un sistema sociotécnico es aquel en el que elementos humanos y técnicos interactúan [4]. Consta de operaciones realizadas por una máquina o un individuo sobre algún material. En este contexto, Cooper y Foster dividen el sistema en unidades de primer y segundo orden.

2.5.1. Unidades de primer orden

Existen dos tipos de unidades de primer orden:

- Actividades realizadas por una persona.
- Operaciones realizadas por una máquina con una configuración determinada.

Estas unidades se reflejan en tres tipos de interacción:

- Asignación de personas a máquinas.
- Asignación de procesos a máquinas.
- Asignación de procesos a personas.

2.5.2. Unidades de segundo orden

Las unidades de segundo orden son agrupaciones de actividades, operaciones o secuencias de procesos que definen trabajos, tipos de máquinas o procesos de producción completos [4].

2.5.3. Complementariedad humano-máquina

La relación entre humanos y máquinas se basa en el principio de complementariedad, que se fundamenta en:

- Reconocer las diferencias de fortalezas entre humanos (adaptabilidad, juicio completo) y máquinas (precisión, rapidez).
- Diseñar condiciones de desempeño adaptadas a las capacidades de humanos y máquinas.
- Garantizar control y motivación, de manera que los humanos puedan desempeñarse de manera óptima como complemento de la máquina [4].

2.6. Fine-Tuning en Modelos de Lenguaje

Una parte importante de los modelos de lenguaje de gran escala (LLM) es la simulación de la comprensión humana. Desde un enfoque hermenéutico, esta comprensión se puede conceptualizar en tres condiciones:

- **Precomprensión**: el punto inicial, formado por las suposiciones previas y la información nueva adquirida.
- **Distanciación**: la representación de las diferentes perspectivas posibles durante el proceso interpretativo.
- **Círculo hermenéutico**: un proceso iterativo donde para entender el todo es necesario comprender cada parte, y para comprender cada parte es necesario conocer el todo.

El objetivo de un LLM es poder realizar tareas cognitivas cumpliendo estas condiciones. Para ello, se utilizan varias estrategias:

Para la **precomprensión**, los LLM se entrenan con grandes cantidades de texto, lo que les permite adquirir una capacidad básica de comprensión [9]. La **distanciación** depende de la habilidad del modelo de adaptar sus respuestas según el contexto [9]. El **círculo hermenéutico** se fortalece mediante entrenamientos continuos y técnicas como el *fine-tuning*, que permite mejorar la comprensión en un dominio específico [9].

La etapa de **preentrenamiento** es la más extensa y exige mayores recursos computacionales, ya que el modelo aprende patrones lingüísticos y conocimientos generales [9].

Por su parte, el **fine-tuning** busca especializar al modelo en un dominio determinado sin sacrificar los patrones aprendidos durante el preentrenamiento, utilizando datos específicos del área de interés [9]. Además de estas técnicas, se emplean:

- **Prompt Engineering**: diseño de prompts que guían el comportamiento del LLM [9].
- **Retrieval-Augmented Generation (RAG)**: permite al modelo acceder a información externa para generar respuestas más precisas [9].
- **Knowledge Distillation**: proceso mediante el cual se transfiere conocimiento de un modelo complejo a uno más simple [9].

Adicionalmente a las técnicas de especialización de modelos, el **Prompt Engineering** se define como el arte y la práctica de diseñar, estructurar y refinar estratégicamente las instrucciones o indicaciones (prompts) enviadas a un modelo de lenguaje para guiar su comportamiento hacia resultados específicos, útiles y precisos [2]. Esta disciplina actúa como un puente de comunicación esencial entre el usuario humano y la inteligencia artificial, permitiendo que el modelo genere respuestas alineadas con objetivos determinados, como la veracidad científica o la neutralidad de tono [2].

Dentro de esta práctica, existen diversas técnicas fundamentales para optimizar la interacción [2]:

- **Zero-shot Prompting**: Consiste en solicitar una tarea al modelo sin proporcionarle ejemplos previos, confiando únicamente en su conocimiento general preentrenado [2].

- **One-shot y Few-shot Prompting**: Implica proporcionar uno o más ejemplos del formato o razonamiento deseado dentro del prompt. Esto ayuda al modelo a comprender patrones complejos y reduce la ambigüedad en la respuesta [2].
- **Chain of Thought (CoT)**: Es una técnica donde se instruye al modelo para que descomponga un problema complejo en pasos intermedios de razonamiento lógico antes de entregar el resultado final [2]. Esta transparencia es vital en contextos académicos para verificar la coherencia de los argumentos.
- **Role-playing**: El diseño de prompts que asignan una "persona.º rol específico al asistente (por ejemplo, .ªctúa como un revisor de pares académico") permite ajustar el nivel de detalle y el estilo lingüístico de la intervención [2].

El uso estratégico de estas técnicas, combinado con la integración de datos externos mediante RAG, permite mitigar problemas comunes como las alucinaciones y asegurar que el asistente sociotécnico promueva una deliberación informada y libre de sesgos [2].

2.7. Deliberación Académica

La deliberación académica se refiere a un proceso estructurado de intercambio de ideas en el que los participantes analizan, cuestionan y justifican afirmaciones con el objetivo de construir conocimiento de manera colectiva. A diferencia de una discusión informal, la deliberación implica la evaluación crítica de argumentos, el uso de evidencia y la disposición a revisar posiciones iniciales frente a nuevas razones o información.

Desde la perspectiva de la teoría de la acción comunicativa, propuesta por Habermas, la deliberación se fundamenta en la búsqueda de entendimiento mutuo mediante el uso del lenguaje orientado al consenso racional. En este contexto, los participantes no solo expresan opiniones, sino que también justifican sus puntos de vista, evalúan los argumentos de otros y están abiertos a la refutación racional.

Un aspecto central de la deliberación es la calidad de los argumentos intercambiados. Esta calidad puede analizarse en términos de claridad, relevancia, coherencia lógica y respaldo en evidencia. Asimismo, la presencia de contraargumentos y réplicas contribuye a enriquecer el proceso deliberativo, ya que permite examinar distintas perspectivas sobre un mismo tema.

En entornos digitales, la deliberación puede verse influenciada por factores como la asincronía, la diversidad de participantes y la mediación tecnológica. En este sentido, los sistemas computacionales pueden desempeñar un rol de apoyo al facilitar la formulación de preguntas, la organización de ideas y la exposición de argumentos relevantes.

La integración de asistentes basados en modelos de lenguaje en procesos deliberativos tiene como objetivo fomentar la reflexión crítica mediante la generación de preguntas que estimulen el análisis profundo, así como la producción de respuestas breves que orienten la discusión sin imponer una postura específica. De esta manera, el sistema actúa como un facilitador que apoya la interacción entre los participantes, promoviendo una participación más informada y estructurada.

En este contexto, la deliberación académica no se limita a la comunicación entre individuos, sino que se extiende a un proceso mediado por sistemas sociotécnicos en los que la tecnología contribuye a mejorar la calidad de las interacciones y a potenciar la construcción colectiva del conocimiento.

2.8. Co-pensamiento y Cognición Híbrida (Humano-IA)

La introducción de los Modelos de Lenguaje de Gran Escala (LLMs) en el ámbito científico ha propiciado una transición desde flujos de trabajo procedimentales y lineales hacia procesos interactivos y dialógicos [5]. En este contexto, la interacción entre el investigador y la inteligencia artificial no se limita a la automatización de tareas, sino que evoluciona hacia un modelo de *co-pensamiento* o cognición híbrida [5].

Bajo este paradigma, el razonamiento se distribuye entre agentes humanos y artificiales. El sistema computacional asume el rol de recuperar, recontextualizar y asociar información a gran velocidad, mientras que el investigador humano retiene la agencia para la interpretación, la evaluación crítica y el control epistémico [5].

La interfaz conversacional funciona, por tanto, como un *andamiaje cognitivo* (cognitive scaffold): un espacio donde el razonamiento individual puede ser externalizado, analizado y refinado de forma iterativa [5]. Esto permite a los investigadores formular preguntas exploratorias, probar la lógica de sus hipótesis y descubrir analogías interdisciplinarias antes de someter sus ideas al escrutinio formal de sus pares [5].

2.8.1. El rol de la IA como mediador en la deliberación

Históricamente, la generación de conocimiento científico estuvo profundamente arraigada en la correspondencia, el diálogo y la disputa académica [5]. El uso de asistentes basados en LLMs reabre este espacio para el debate al actuar como intermediarios o catalizadores conversacionales. En entornos como las redes sociales académicas, estas herramientas fungen como interlocutores que, si bien carecen de intencionalidad, poseen la capacidad de reflejar y expandir los procesos de pensamiacento del usuario [5].

Esta dinámica recursiva transforma la deliberación en un ciclo continuo: una pregunta genera una respuesta que, a su vez, siembra la base para una interrogante más profunda, acelerando el refinamiento analítico y la creatividad científica [5].

2.8.2. Riesgos epistémicos y descarga cognitiva

A pesar de sus ventajas, la fluidez lingüística de los LLMs introduce vulnerabilidades en el proceso deliberativo. Uno de los mayores riesgos es la *descarga cognitiva* (cognitive offloading), fenómeno que ocurre cuando el investigador delega su esfuerzo de razonamiento en el sistema externo, motivado por la aparente confianza y coherencia de las respuestas generadas [5].

La coherencia de la IA puede enmascarar la incertidumbre o el sesgo, creando una ilusión de rigor [5]. Por esta razón, el diseño de asistentes sociotécnicos para la deliberación requiere la implementación de "guardrails.º barreras éticas que fomenten la vigilancia epistémica [5]. El objetivo del sistema no debe ser persuadir ni proporcionar respuestas definitivas, sino mantener la indagación activa, requiriendo que el usuario mantenga una postura crítica frente a la información generada [5].

Capítulo 3

Metodología

3.1. CRISP-DM

En nuestro estudio se desarrolla el sistema CENTINELA, una plataforma sociotécnica orientada a la colaboración e investigación científica, enfocándose en el componente de un Asistente sociotécnico basado en modelos de lenguaje para la deliberación y expansión del conocimiento en el módulo de búsqueda.

Al ser un sistema centrado en la generación de preguntas y respuestas mediante el análisis y la retroalimentación de artículos científicos, se plantea como solución el uso y la evaluación de modelos de lenguaje de gran escala (LLM), combinados con técnicas de Generación Aumentada por Recuperación (RAG, por sus siglas en inglés). Este último enfoque involucra el proceso de recuperar y extraer información de una base de datos externa; debido a que nuestra propuesta de solución es inherentemente centrada en los datos, utilizaremos la metodología CRISP-DM [6] como guía para el proceso de desarrollo.

CRISP-DM es un estándar enfocado en la minería de datos, consta de 6 fases, con un flujo referencial definido, es decir, tiene la capacidad de regresar y avanzar entre sus etapas, acorde al análisis y desarrollo del proyecto. Al tener esta ventaja adaptable, podemos juntarla con enfoques ágiles e iterativos, promovidos por la parte de su respectiva implementación dentro del sistema de software CENTINELA V3.

CRISP-DM consta de las siguientes etapas:

3.1.1. Entendimiento del negocio

Esta etapa está centrada en conocer la situación de la organización, es decir sus recursos, materiales, problemas y metas; en nuestro estudio en esta etapa nos centramos en hacer un análisis de la arquitectura, código y despliegue del sistema CENTINELA V3, con un enfoque principal en el motor de búsqueda actual y los flujos y mecanismos de recuperación de información existentes.

3.1.2. Comprensión de los datos

CRISP-DM dice que aquí debemos observar y analizar los datos de los que disponemos. Es decir, que verificamos la calidad de los datos y mecanismos de preparación. Como resultado debemos tener un Informe de descripción de datos, donde se involucre esquemas, atributos, cantidad y cualquier otra característica relevante para nuestros procesos.

3.1.3. Preparación de los datos

La preparación de los datos consta de la elección y ejecución de procesos como fusiones, selecciones, limpieza, ordenaciones, divisiones y transformaciones de datos, para cumplir con nuestro objetivo. En esta etapa se deben trabajar los datos para que nuestro modelo los pueda usar e integrar de manera eficiente en la generación de respuestas (Question Generation/Question Answering).

3.1.4. Modelado

En esta etapa se decide qué técnica de modelado se usará, o qué modelo ya entrenado se usará como base; nos encargamos de la configuración de sus parámetros. Como resultado tenemos un Informe sobre la interpretación de modelos resultantes. En nuestro estudio, nos centraremos en la selección del modelo más óptimo para nuestro Asistente sociotécnico y la configuración de su System Prompt y extracción de datos por medio de RAG. Finalmente haremos una evaluación interpretada en base al conocimiento de su implementación en el sistema CENTINELA V3.

3.1.5. Evaluación

Esta etapa se centra en evaluar el modelo en base al cumplimiento de los objetivos definidos en el Entendimiento del negocio. Esto implica que esta evaluación se hará dentro de CENTINELA V3, una vez esté implementada ya la funcionalidad del Asistente sociotécnico, midiendo su impacto y rendimiento dentro del sistema global.

3.1.6. Despliegue

En base a los resultados de la evaluación, se determina una estrategia de implementación. CENTINELA V3 tiene procesos ya definidos de despliegue, con pipelines de pruebas y QA establecidos; por lo tanto, nos centraremos en entregar un incremento funcional que cumpla los estándares dados y se integre correctamente en el entorno.

3.2. Kanban

Kanban es un marco ágil centrado en la gestión del trabajo, posee una gran flexibilidad, por lo que puede adaptarse a una variedad de proyectos para gestionar y mantener un correcto flujo de actividades [1]. Consta de cuatro principios: visualizar el flujo de trabajo, limitar el trabajo en curso, gestionar el flujo y mejorar continuamente.

Para nuestro proyecto, su adaptabilidad nos permite usarlo junto a CRISP-DM en las etapas vinculadas al desarrollo y evaluación del modelo, como a la parte de implementación y evaluación dentro del sistema CENTINELA V3.

De manera clara, Kanban no define una cantidad de miembros o roles, por lo que queda a decisión del encargado manejar los equipos; en base a esta justificación usamos este marco para un uso individual centrados solo en nuestro componente de desarrollo de un Asistente sociotécnico.

3.2.1. Tableros Kanban

Es el elemento principal que nos permite gestionar nuestras tareas y su estado de manera transparente. Es importante limitar el trabajo en curso (WIP), de modo que

no nos sobrecarguemos de tareas En progreso. La limitación de trabajo en curso se decide por criterio de la capacidad del equipo. Esta técnica nos ayuda a prevenir los cuellos de botella, inactividad y fomenta las prácticas ágiles. Para limitar el WIP, se pueden usar otras métricas como Story Points, horas esfuerzo, etc. Así, se consideró tener 4 estados para las tareas: "Por hacer", .En progreso", .En revisiónz "Terminadas", del mismo modo se usarán horas esfuerzo para manejar nuestro WIP.

3.2.2. Tarjetas Kanban

Cada tarjeta es una representación de una tarea, pueden contener información como persona encargada, prioridad, contexto, etc.

3.2.3. Backlog

Normalmente todas las tareas pendientes se colocan en la columna "Por hacer", sin embargo, para nuestra conveniencia y facilidad de priorización y trabajo se incorporan los backlogs dentro de nuestro marco de trabajo. Su justificación se basa en la gran cantidad y poco refinamiento de los ítems, de este modo podemos priorizar y bajar el nivel de los ítems en tareas, en base a nuestro progreso. Así, la incorporación de tareas a nuestro Tablero Kanban es más eficiente.

3.2.4. Métricas

Para la mejora continua debemos llevar métricas de nuestro rendimiento. Las principales métricas contempladas son: Plazo (tiempo desde que se añade una tarea a que es completada), Duración del ciclo (tiempo desde que una tarea comienza hasta que es completada) y Producción (número de tareas completadas en un tiempo determinado). Para la visualización de las métricas se configuran gráficos de control y diagramas de flujo acumulado.

3.3. Integración de metodologías y marcos de trabajo

Para la correcta ejecución del proyecto, las fases definidas en CRISP-DM serán la base para la planeación de las actividades, que recursivamente irán dentro de nuestro Backlog. Es decir, las actividades requeridas para el entendimiento, preparación,

modelado y evaluación de los datos se transformarán en ítems y tareas dentro de nuestro tablero Kanban. Para llevar el control de todo este flujo de trabajo y visualizar nuestras métricas de manera transparente, se usará la plataforma de Azure (Azure DevOps). Esta herramienta nos permite configurar nuestro tablero, gestionar los estados de las tarjetas y mantener un seguimiento claro de nuestro WIP y progreso en el desarrollo del Asistente sociotécnico. Adicionalmente, ofrece otras utilidades para la gestión del proyecto como el control de versiones, configuración de dashboards, construcción de Pipelines, entre otras que nos pueden ser útiles.

Bibliografía

[1] Atlassian. ¿Qué es la metodología Kanban? https://www.atlassian.com/es/agile/kanban, s.f. Accedido el 29 de julio de 2026.

[2] Bansal, P. Prompt Engineering Importance and Applicability with Generative AI. *Journal of Computer and Communications*, 12:14–23, 2024.

[3] Bench-Capon, T. J. M. y Dunne, P. E. Argumentation in Artificial Intelligence. *Artificial Intelligence*, 171(10-15):619–641, 2007.

[4] Cooper, R. y Foster, M. Sociotechnical Systems. *American Psychologist*, 26(5):467–474, 1971.

[5] Gavrilova, A. V. y Galli, C. Conversing with machines: How AI is changing the way scientists think. *Quantitative Biology*, 2026.

[6] IBM. Guía de introducción a CRISP-DM. https://www.ibm.com/docs/es/spss-modeler/saas?topic=guide-introduction-crisp-dm, 2021.

[7] Mulla, N. y Gharpure, P. Automatic question generation: a review of methodologies, datasets, evaluation metrics, and applications. *Springer*, 2023.

[8] Uttarwar, S., Gambani, S., Thakkar, T., y Mulla, N. Machine Learning Based Review on Development and Classification of Question-Answering Systems. En *Proceedings of the Third International Conference on Computing Methodologies and Communication (ICCMC)*, India, 2019.

[9] Wu, X.-K., Chen, M., Li, W., Wang, R., Lu, L., Liu, J., Hwang, K., Hao, Y., Pan, Y., Meng, Q., Huang, K., Hu, L., Guizani, M., Chao, N., Fortino, G., Lin, F., Tian, Y., Niyato, D., y Wang, F.-Y. LLM Fine-Tuning: Concepts, Opportunities, and Challenges. *Big Data Cogn. Comput.*, 9:87, 2025.

[10] Zhang, R., Guo, J., Chen, L., Fan, Y., y Cheng, X. A Review on Question Generation from Natural Language Text. *ACM Transactions on Information Systems*, 2021.